

Nombre y Apellidos: Fernando Urrutia Gómez-Menor

Github con notebook: https://github.com/Ahcelf/davd_Fernando_EuropeanMigration


Nota: Por favor, seguir esta estructura para el documento

1. Resumen Ejecutivo

Máximo 2 páginas

Escribe aquí tu resumen ejecutivo con el dashboard, hallazgos del análisis descriptivo que se observan el dashboard, insights del modelo predictivo y recomendaciones accionables basadas en los datos.

DASHBOARD



Con el objetivo final de determinar qué variables de nuestros clientes afectan más al precio que del seguro se ha llevado a cabo un análisis exhaustivo de relaciones entre variables y el monto anual que pagan.

Como punto de partida se determina como es la distribución de estas cantidades anuales, y con qué frecuencia se dan. Es decir, qué dinero se recibe normalmente de cada cliente. Esta distribución es claramente asimétrica donde la mayoría de los costes se encuentran en la zona \$1k-\$5k. La media del seguro es de \$3k y la mediana en torno a los \$2,8k.

Además, existen alrededor de 1000 clientes cuyo seguro anual supera los \$10k. Estos podrían considerarse clientes VIP.

¿Pero, cómo podemos encontrar a esos clientes?

Primero se ha realizado una búsqueda por edad, sexo, región y estado civil marital. Pese a que de nuevo se encuentran las mismas agrupaciones en torno a valores de \$2k anuales, se ha observado que a medida que el cliente es más mayor y está casado, el seguro tiene un valor mayor. La distribución por género no ofrece resultados muy llamativos, aunque se observa una mayor tendencia a valores altos en mujeres. Por último, la región tampoco parece afectar en exceso al valor del seguro.

A continuación, se realiza otra fragmentación de los costes, pero en este caso por hábitos de vida de los clientes.

Para los fumadores, el coste del seguro es mayor en aquellos que actualmente fuman y en aquellos que fumaron en algún momento de su vida.

En cuanto a la ingesta de alcohol, el riesgo no parece aumentar excesivamente con personas que beben semanal o diariamente. Se entiende así que el alcohol al estar más normalizado no tiene esta importancia.

Como comentario adicional creo que sería adecuado ver, no solo la frecuencia de consumo, que, como digo, es algo más normalizado en la sociedad, si no la cantidad de consumo que sí que puede tener mayores implicaciones tanto en el riesgo del cliente, como por ende en el valor del seguro.

Más adelante se ha llevado a cabo una búsqueda de correlaciones entre información clínica (como enfermedades pasadas) y el riesgo y coste anual del seguro. En este caso, variables como visitas durante el año pasado o enfermedades crónicas parecen influenciar ambas variables objetivo.

Por último, se ha desarrollado una clusterización de los clientes por riesgo y coste anual pagado llegando a tres grupos:


- Riesgo bajo (<0.4) y coste bajo ($<\$10k$)
- Riesgo moderado/alto (≥ 0.4) y coste bajo ($<\$10k$)
- Riesgo alto (≥ 0.4) y coste alto ($>\$10k$)

Para nuestra aseguradora, lo mejor sería “atacar” el grupo intermedio y buscar como aumentar el coste de los seguros a personas que realmente presentan un riesgo mayor.


Para confirmar las hipótesis del análisis exploratorio de los datos se ha implementado una regresión lineal que trata de estimar qué variables de las mencionadas realmente tienen esa influencia en el coste anual del seguro.

Para más información ver apartado 3. Modelo predictivo y tablas.

2. Gráficas del análisis exploratorio y breve explicación de cada una




La distribución de del coste médico anual para comprobar rápidamente en qué intervalos de ingresos se mueve la aseguradora. Se calcula media y mediana para mayor interpretación de los datos. Esta gráfica también da una idea de que existen muchos valores atípicos a partir de cifras en torno a \$15k.




Con esta distribución por columnas sencilla se observa rápidamente si la variable Smoker tiene influencia en las variables target. Se fragmente según los posibles valores del fumador: actual, histórico o nunca ha fumado.


II. Análisis del Coste anual por Demografía




El objetivo de esta multi-visualización es comprobar la relación entre variables demográficas y personales con el coste anual que se paga a la aseguradora. Se puede comprobar cambios según el grupo de edad perteneciente o muy llamativos en el estado civil.



Esta gráfica de puntos permite visualizar la relación entre la frecuencia de ingesta de alcohol y el coste anual del seguro. Se observa que realmente no hay una tendencia muy clara.



La matriz de correlaciones se hace para ver la relación numérica entre variables clínicas como distintos tipos de enfermedades y si suponen un mayor riesgo o influyen en la cantidad que se paga al seguro.



Por último, la gráfica de cluster por las dos variables objetivo permite identificar segmentos de clientes de la aseguradora (explciados en el resumen ejecutivo)

3. Modelo predictivo explicado y con tablas

Escribe aquí sobre tu modelo, qué predice, qué variables ha utilizado, métricas o tablas de evaluación y gráfico de coeficientes para explicar el modelo.


El modelo de regresión lineal busca confirmar las hipótesis anteriores y servir a la aseguradora como modelo para estimar el valor que se debería cobrar por cada seguro dependiendo de las características de los clientes.

En este caso no se ha conseguido una explicación demasiado fuerte ya que solo un 12,5% de la varianza se explica con las variables seleccionadas. El error también es alto lo que puede indicar que el modelo se puede mejorar.

R2: 0.1248

RMSE: \$2,934.68

No obstante, el modelo sí que confirma muchas de las hipótesis realizadas:



La variable *Smoker* es una de las más explicativas del precio del seguro, junto a la edad o enfermedades pasadas.

Se confirma que la variable *Alcohol_freq* no tiene influencia mayor.

El estado civil sin embargo, no parece tener realmente esa importancia que parecía en un principio.